

DATAANALYSE, ERHVERVSAKADAMIET DANIA



Nicklas Helmundt
Nicklas Wollesen
Nikolaj Aaby Larsen
Nicolaj Andersen
Mathias Ødegaard Andersen

2. SEMESTERPROJEKT

CASE: JP

6. Maj 2026

Antal anslag:

Indholdsfortegnelse

1	Forretningsproblem for JP	1
1.1	Problemstilling	1
1.2	Problembeskrivelse	1
1.3	Afgrænsning	1
2	Juridisk Metode	2
2.1	JP og datajura	2
2.2	Er JP's data personoplysninger?	2
2.3	Grundlæggende principper	2
2.4	Behandlingsgrundlag og interesseafvejning	2
2.5	Automatiseret beslutningstagning	2
2.6	AI-forordningen	2
2.7	Bias og ligebehandling	3
2.8	Cybersikkerhed og behandlingssikkerhed	3
2.9	Markedsføringsloven og registreredes rettigheder	3
2.10	Samlede juridiske anbefalinger	3
3	Videnskabsteori og metode	4
3.1	Videnskabsteori	4
3.2	Metode	4
4	Machine Learning i praksis for JP - Churn prediction	5
4.1	Valg af klassifikationsmodeller	5
4.2	Logistisk Regression	5
4.3	Random Forest	5
4.4	XGBoosting	5
4.4.1	Hvorfor XGBoost og ikke andre boosting-modeller?	5
4.5	Begrundelse for fravalg af andre modeller	5
4.5.1	K-Nearest Neighbor (KNN)	5
4.5.2	Naive Bayes (NB)	6
4.5.3	Support Vector Machine (SVM)	6
5	Machine Learning i praksis for JP - Segmentering af kunder	7
5.1	Unsupervised learning - Klyngeanalyse	7
5.1.1	Anvendelse af Gower-distance	7
5.1.2	Begrundelse for fravalg af en Principal Component Analysis (PCA)	7
6	Implementering af neurale netværk og deep-learning for JP	8
6.1	Opbygning af et neural netværk	8
6.2	Fordele og ulemper ved en Neural Netværk (NN) model	8
6.3	Hvad der kræves af JP, for at implementere en Neural Netværk (NN) model	8
6.4	Hvilken Neural Netværk (NN) model der anvendes i opgaven	8
7	Klyngeanalyse til PowerBI visualisering.	9
8	Dataklargørelse	10
9	Modellering - Klyngeanalyse	15
9.1	Dataklargøring til modellering	15
9.2	Klyngeanalyse	15
9.3	Klyngeprofiler	16
9.4	Visualisering	18
9.5	Gem som CSV-filer til Power BI	19
10	Modellering - Churn i kampagnen	20

10.1	Dataklargøring til modellering	20
10.2	Håndtering korrelerede variabler	21
10.3	Opsætning af cross-validation kontrol til modevaluering.	23
10.4	Logistisk Regression	23
10.5	Random Forest	26
10.6	XGBoost	27
10.7	Tabel over mest risikable kunder	29
10.8	Økonomisk analyse af churn-kampagne	30
10.9	Sammenligning af modeller	31
10.10	Cross-validation sammenligning	34
10.11	Gem som CSV-filer til Power BI	35
11	Modellering - Churn kort tid efter kampagnen	35
11.1	Dataklargøring til modellering	35
11.2	Håndtering korrelerede variabler	36
11.3	Opsætning af cross-validation kontrol til modevaluering.	37
11.4	Logistisk Regression	37
11.5	Random Forest	38
11.6	XGBoost	38
11.7	Tabel over mest risikable kunder	40
11.8	Økonomisk analyse af churn efter kampagnen	40
11.9	Sammenligning af modeller	41
11.10	Cross-validation sammenligning	46
11.11	em som CSV-filer til Power BI	46
12	Væsentligste konklusioner	48
13	Literaturliste	49
A	Dataforståelse (CRISP-DM)	50
A.1	Forretningsforståelse	50
A.2	Dataforståelse	50
A.3	Dataklargøring	50
A.4	Modellering	50
A.5	Evaluerig	50
A.6	Implementering	50
B	Dataklargørelse	51
B.1	Hente data fra Superstats og gør dem tidy	51
B.2	Hente data fra DMI og gør dem tidy	51
B.3	Hente data fra nager.at og gør dem tidy	51
B.4	Hente Bjarnes data og gør dem tidy	51
B.5	RSQLight	51
B.6	Download jointet datasæt, formatér behørigt, og gør data klar til preprocessing	51
B.7	Preprocess - dan flere variabler og lav ét datasæt uden missing med en række for hver hjemme- kamp, og fjern alle variabler, som ikke skal indgå i	51
C	Modellering - herunder opdeling i et trænings- og testdatasæt - med et seed = jeres hold- nummer.	51
C.1	Stor model - linenær regression med alle variabler	51
C.2	Lasso / Ridge - husk at bruge CV til at optimere lambda	51
C.3	Subset selection metoder (brug mindst én)	51
C.4	Sammenlign på validation de forskellige MSE fra hver model	51
D	Evaluerig	51
D.1	Hvordan er Test-MSE sammenlignet med CV-MSE	51
D.2	Fortokning	51

D.3	Prædiktion på nye data (fx best-case/worst-case scenario for de første kampe i foråret)	51
D.4	Sammenlign resultatet med formålet med undersøgelsen.	51
E	Eksempler på markdown-sproget	51
E.1	Her hentes et billede	51
E.2	Referencer	51
F	Fed og kursiv, og punktform	53
G	Formler (m.m)	53
G.1	Gennemsnit	53

Indholdsfortegnelse

Figuroversigt

1	Faserne i CRISP-DM.	52
2	Australsk BNP pr capita	52

Tabeloversigt

1	Sammenligning af modeller — Model 1 (churn ved kampagneslut)	31
2	Sammenligning af modeller — Model 2 (churn inden for 10 dage efter kampagneslut)	42
3	Outliers og indflydelsesrige observationer.	52

1 Forretningsproblem for JP

1.1 Problemstilling

En høj churn-rate påvirker JP's økonomiske stabilitet og dens vækstmuligheder. En høj churn-værdi øger JP's behov for konstant at tiltrække nye kunder, da den tilbagevendende indtægt reduceres. Samtidigt indikerer en høj churn-rate, at produktværdien fanger forbrugerens opmærksomhed, men ikke skaber den tilstrækkelige værdi i et konkurrencepræget marked hvor der er mulighed for at få samme kampagnetilbud ved en konkurrent eller finde andre gratis alternativer. Problemstillingen er derfor at identificere årsagerne til churn blandt digitale abonnementer og hvordan de kan øge kundeloyalitet og fastholdelsesprocenten.

1.2 Problembeskrivelse

JP oplever et stort frafald blandt de kunder, som starter gennem et kampagneabonnement (2 måneder for 49 kr.). En signifikant del af disse kunder opsiger deres abonnement under kampagnen eller umiddelbart efter kampagneperioden og vælger ikke at fortsætte til standardprisen. Dette betyder, at JP's ikke anvender deres ressourcer optimalt og virksomheden står derfor overfor behovet for at forbedre kundeværdien og dermed reducere churn-rate.

1.3 Afgrænsning

2 Juridisk Metode

2.1 JP og datajura

JP/Politikens hus indsamler og behandler adfærdsdata og abonnementsoplysninger fra deres digitale platforme med henblik på blandt andet at udvikle churn prædiktionsmodeller, som kan understøtte den målrettede fastholdelse af abonnenter. Behandlingen rejser juridiske spørgsmål under GDPR, markedsføringsloven, AI forordningen og NIS2 direktivet. Den lovgivningsmæssige ramme og de relevante retskilder er nærmere beskrevet i Bilag – juridisk analyse afsnit 1.

2.2 Er JP's data personoplysninger?

Datasættet indeholder `pseudo_id`, fødselsdato, køn og detaljerede adfærdsdata, herunder sidevisninger, scroll-dybde, devicetype og trafikkilde for over 1200 abonnenter. Selvom data er pseudonymiserede, udgør kombinationen heraf 'personoplysninger' i GDPR's forstand, jf. art. 4, nr. 1, da re-identifikation er mulig. Hvad der er afgørende, er at JP selv besidder nøglen til sammenkoblingen via `pseudo_id`. GDPR og databeskyttelsesloven finder derfor fuld anvendelse her. Nærmere analyse fremgår af Bilag, afsnit 2.

2.3 Grundlæggende principper

JP's behandling skal overholde de 7 principper i GDPR art. 5. De mest relevante for churn analysen er formålsbegrænsning, dataminimering og opbevaringsbegrænsning. Data indsamlet til abonnementsadministration kan ikke bare uden videre anvendes til churn profilering, medmindre dette er foreneligt med det oprindelige formål, jf. forenelighedstesten i art. 6, stk. 4. Adfærdsprofilering til retention formål er ikke direkte foreneligt med abonnementsadministration. Tekniske metoder som fx PCA, klyngeanalyse samt VIF-test kan identificere overflødige og korrelerede variable, og udgør dermed okumentation for overholdelse af dataminimeringsprincippet som er en direkte kobling mellem dataanalyse og juridisk compliance. JP's delvise overholdelse af art. 5. samt de væsentligste mangler analyseres i Bilag, afsnit 3.

2.4 Behandlingsgrundlag og interesseafvejning

Abonnementsadministration kan behandles på grundlag af kontraktopfyldelse jf. art. 6. stk. 1, litra b. churn profilering udgør derimod et nyt formål, som kræver selvstændig hjemmel. Legitim interesse litra f, kan udgøre lovligt grundlag, men forudsætter også at JP gennemfører og dokumenterer en interesseafvejning (LIA – legitimate interest assessment). JP's interesse i at fastholde abonnenter er konkret og saglig og en churn model vurderes til at være et proportionelt virkemiddel, en grovere demografisk segmenteringsmodel ville forstyrre en bredere gruppe, og give værre præcision. Abonnenter kan med rimelighed ikke forvente at data som eksempel scroll dybde og devicetype anvendes til individuel profilering, hvilket udgør en modvægt i afvejningen. Den legitime interesse kræver en opdateret privatlivspolitik samt en reel indsigelsesmulighed jf. art. 21. Det er derudover afgørende at holde markedsføringssamtykket strengt adskilt fra GDPR behandlingsgrundlaget. Samtykke til elektronisk markedsføring efter markedsføringsloven §10 er ikke identisk med GDPR retligt behandlingsgrundlag og de to regelsæt må ikke sammenblandes. Den fulde interesseafvejning fremgår af bilag, afsnit 4.

2.5 Automatiseret beslutningstagning

JP's churn modeller genererer en sandsynlighedsscore pr abonnent, som benyttes til beslutningsstøtte. Så længe JP's medarbejdere foretager en substantiel og ikke blot formel vurdering forud for enhver retention beslutning, finder GDPR art. 22. ikke anvendelse. Hvis tildelingen af fastholdelsestilbud automatiseres direkte fra modellens output uden menneskelig prøvelse, aktiveres art. 22. og JP skal sikre ret til menneskelig indgriben, indsigt i beslutningslogikken og mulighed for at bestride afgørelsen jf. art. 22. stk. 3. Analysen fremgår af Bilag, afsnit 5.

2.6 AI-forordningen

JP's churn modeller, opbygget med logistisk regression, random forest & XGBoost udgør AI systemer i AI Act forstand jf. art. 3, nr 1. Modellerne falder hverken indenfor de forbudte kategorier i art. 5. eller højrisiko kategorierne i bilag III og klassificeres derfor som begrænset risiko (niveau 3) jf. art. 50. Derudover bemærkes det,

at størstedelen af AI Acts forpligtelser først finder fuld anvendelse fra August 2026, mens transparenskravene allerede er relevante; abonnenter skal informeres om profilering og derfor bør JP dokumentere modellernes formål og datagrundlag. Den fulde risikoklassificering fremgår af Bilag, afsnit 6.

2.7 Bias og ligebehandling

Da alder og køn indgår som forklarende variable i modellerne, er der risiko for der sker systematisk indirekte diskrimination over for grupper med beskyttede karakteristika. JP bør løbende evaluere modellernes sensitivitet og specificitet på tværs af demografiske grupper. Såfremt systematisk skæv behandling identificeres, bør relevante variable rekonstrueres eller fjernes helt, hvilket er et tiltag som understøtter dataminimeringsprincippet i art. 5. stk. 1, litra c. Bilag, afsnit 7.

2.8 Cybersikkerhed og behandlingssikkerhed

Sikkerhedsbrud i JP's systemer ville potentielt muliggøre reidentifikation af samtlige registrerede. Pseudonymisering er utilstrækkeligt som eneste sikkerhedsforanstaltning. JP bør supplere med kryptering i hvile og under transmission, rollebaseret adgangsstyring med logging og dokumenterede procedurer for sikkerhedsbrud, herunder underretning til Datatilsynet inden 72 timer jf. art. 33. og til de registrerede jf. art. 34. Som en stor digital medieuudbyder kan JP desuden falde indenfor NIS2 direktivets anvendelsesområde, som blandt andet pålægger indledende underretningspligt inden 24 timer ved væsentlige hændelser. ISO/IEC 27001 certificering anbefales som dokumentation for et systematisk informationssikkerhedsstyringssystem. Bilag, afsnit 8.

2.9 Markedsføringsloven og registreredes rettigheder

JP's retention kommunikation henter typisk hjemmel i undtagelsen for eksisterende kundeforhold (soft opt-in) jf. markedsføringsloven §10 med forudsætning af, at der gives en klar og tydelig frameldingsmulighed. Trækker en abonnent sit samtykke tilbage, skal JP omgående stoppe med direkte markedsføring, mens behandling til øvrige formål kan fortsætte under dettes selvstændige hjemmelgrundlag. JP bør også implementere tilgængelige, lavpraktiske procedurer for udøvelse af de registrerede rettigheder; indsigt (art. 15) berigtigelse (art. 16) sletning (art. 17) og indsigelse mod behandling baseret på legitim interesse, som er særligt relevant for churn profilering jf. art. 21. Bilag, afsnit 9.

2.10 Samlede juridiske anbefalinger

På baggrund af ovenstående analyse, anbefales det, at JP iværksætter og sikrer følgende tiltag:

- Udarbejdelse og dokumentation af en LIA (Legitimate Interest Assessment) for churn profilering, inden behandlingen påbegyndes eller videreføres
- Opdater privatlivspolitikken til eksplicit at omtale profileringen og churn modellering, herunder opfyld oplysningspligten over for abonnenter ved dataindsamlingens tidspunkt jf. art. 13, stk. 2, litra f. ikke blot ved opdatering af hjemmesiden privatlivspolitik.
- Fastsæt konkrete opbevaringsfrister og implementer sletningsprocedurer for rådata, efter modellerne er trænet og valideret, jf. art. 5. stk. 1, litra e. Anvend PCA, VIF test & klyngeanalyse til dokumenteret reduktion af variable, som teknisk argumentation for sikker overholdelse af dataminimeringsprincippet.
- Sikre substantiel menneskelig prøvelse af modellernes outputs, forud for enhver beslutning om retention for at undgå aktivering af art. 22.
- Evaluering af modellernes outputs på tværs af demografiske grupper, og undgå systematisk bias ved at rekonstruere eller fjerne kritiske variable.
- Supplering af pseudonymisering med kryptering, rollebaseret adgangsstyring og dokumenterede procedurer i overensstemmelse med art. 32 & NIS2
- Forberedelse af fuld AI Act compliance inden august 2026, hvor dokumentation af modellernes formål, datagrundlag og transparensforpligtelser over for abonnenter indgår.

3 Videnskabsteori og metode

3.1 Videnskabsteori

Projektet tager udgangspunkt i et kritisk realistisk paradigme, da kunde churns kan påvirkes af flere underliggende mekanismer og betragtes som et observerbart fænomen. Kritisk realisme tager i denne sammenhæng udgangspunkt i, at de mekanismer, der driver kundeadfærd og churn i JP's abonnementsforretning, eksisterer uafhængigt af analysen, men kun kan afdækkes indirekte gennem empiriske data. Indsigt i disse mekanismer opnås derfor ved at analysere brugerdata fra JP's digitale platforme og anvende statistiske modeller, som kan identificere mønstre i f.eks. kunders scrolling adfærd, engagement og generelle abonnements dynamikker. I forhold til ontologi anses churns som et systematisk fænomen frem for en tilfældig hændelse, kunders frafald påvirkes af identificerbare faktorer relateret til deres adfærd og oplevelse af produktet. Det anerkendes dog, at ikke alle relevante mekanismer kan observeres direkte, og at uobserverede forhold f.eks. individuelle præferencer eller eksterne markedsforhold kan spille en rolle. I forhold til et epistemologisk perspektiv baseres viden i projektet på empiriske analyser af historiske kundedata, hvor machine learning anvendes til at afdække mønstre og relationer mellem forklarende variabler og churns. Modellerne anvendes til at identificere, hvilke faktorer der har mest betydning i forhold til kundetab. Metodisk anlægges en kvantitativ tilgang med udgangspunkt i sekundære data fra JP's datakilder. De anvendte modeller er bygget op på et positivistisk fundament, da de forsøger at kvantificere sammenhænge og generalisere på tværs af observationer. Undersøgelsesdesignet er deduktivt, da etablerede machine learning metoder anvendes til at teste modellernes evne til at forudsige churns. Der indgår også abduktive elementer, hvor resultaterne bruges til løbende at justere featurevalg og til at fortolke potentielle sammenhænge. Datagrundlaget består primært af kvantitative variabler såsom brugerfrekvens, engagementsniveau og abonnementsoplysninger, og er suppleret med kvalitative indsigter fra JP, der kan bidrage til en mere nuanceret forståelse.

3.2 Metode

Til modellering anvendes klassifikationsmodeller, der estimerer sandsynligheden for churn. Validiteten sikres gennem test på data, mens reliabiliteten understøttes af en konsistent og reproducerbar analyseproces. Resultaternes kvalitet afhænger i høj grad af datagrundlaget og de valgte features, hvilket understreger betydningen af en god datarensning.

4 Machine Learning i praksis for JP - Churn prediction

4.1 Valg af klassifikationsmodeller

I projektet anvendes der klassifikationsmodeller, som forudsiger den procentvis sandsynlighed for churn ved en kunde. Her trænes modellen på kundedata og adfærdsvariabler, og outputtet er sandsynligheden for churns. Det gør det muligt at identificere de kunder, der har høj risiko for at opsige deres abonnement, og dermed målrette retention-indsatser mere effektivt. Til træningen anvendes der både logistisk regression, Random Forest og XGBoost, og modellerne evalueres på en hold-out testdata med metrics som AUC, accuracy, sensitivity og specificity for at sikre robust performance. Her anvendes modellerne også i en bevidst rækkefølge, hvor man gradvist øger kompleksiteten og performance, samtidig med at man opbevarer forståelsen af dataene. De vigtigste features identificeres også, så JP kan forstå, hvilke faktorer der påvirker churn mest. Denne tilgang giver en kombination af præcision og forståelse, som understøtter JP's beslutninger omkring fastholdelse af deres kunder.

4.2 Logistisk Regression

Begrundelsen for valget om logistisk regression model er fordi det er den, der er lettest at fortolke på. Den fungerer derfor som en "baseline-model", som anvendes til at sammenligne alle de andre modeller med. Dette giver en direkte indsigt i den sammenhæng der er i dataene, hvilket kan ses ved koefficienterne, og dermed kan der identificeres de mest signifikante faktorer for churn.

4.3 Random Forest

Der laves en Random Forest model, som anvendes for at fange mere komplekse mønstre, da den har en højere varians end en logistisk regression. Random Forest kan også håndtere ikke-lineære relationer, og er robust over for støj og outliers. Dette gør at modellens performance forbedres i forhold til den logistiske regressionsmodel, samt at der kan afdækkes interaktioner mellem variablerne.

4.4 XGBoosting

En XGBoost-model har en meget høj præcision, og er meget effektiv til at håndtere komplekse datastrukturer. Udover det, så har XGBoost også indbygget regularisering, som reducerer den støj, som modellen opsamler og dermed reducerer overfitting. Boosting fungerer ved at bygge modeller sekventielt, hvor hver nye model retter fejlene fra de forrige model.

4.4.1 Hvorfor XGBoost og ikke andre boosting-modeller?

XGBoost har en indbygget L1 og L2-regularisering, som reducerer overfitting, hvilket en klassisk Gradient Boosting model ikke har, derfor er XGBoost et bedre valg end en klassisk Gradient Boosting model. Der er også andre boosting modeller, som f.eks. AdaBoost, hvilket er en model som fokuserer meget på fejklassificerede observationer, hvilket gør den mere følsom over for støj og outliers frem for en XGBoost-model, hvilket er årsagen til, at denne model fravælges. Til sidst er der også LightGBM-modellen, som er hurtigere og mere memory-effektiv end XGBoost-modellen, men også mere følsom over for støj og overfitting, derfor vil en XGBoost-model være et sikrere valg i et forretningscase som denne.

4.5 Begrundelse for fravalg af andre modeller

Grunden til, at der fravælges modeller som KNN, Naive Bayes og SVM, er primært baseret på deres begrænsninger i forhold til datasættet og formålet med churn-prediktionen. Der gennemgås nu begrundelsen for fravalget af hver enkelt model.

4.5.1 K-Nearest Neighbor (KNN)

KNN kan være udfordrende med større datasæt, da det er beregningsmæssigt tungt og følsomt over for skala og irrelevant variabel.

4.5.2 Naive Bayes (NB)

NB antager uafhængighed mellem features, hvilket sjældent holder i praksis for komplekse kundedata med afhængige adfærdsvariable, hvilket kan føre til dårlig præcision.

4.5.3 Support Vector Machine (SVM)

SVM kan give gode resultater, men kræver ofte omfattende tuning af kerner og hyperparametre, og det er mindre intuitivt at fortolke feature-vigtighed, hvilket gør det mindre egnet til at understøtte beslutninger om retention-strategier.

5 Machine Learning i praksis for JP - Segmentering af kunder

5.1 Unsupervised learning - Klyngeanalyse

Når man segmenterer JP's kundetyper, så anvender man en unsupervised learning metode, da man ikke har en afhængig variabel (y). I modsætning til klassifikationsmodeller forsøger man her at finde strukturer og mønstre i data uden foruddefinerede labels. Klyngeanalyse benyttes, som en machine learning-metode, der automatisk opdeler observationer i grupper (klynger) baseret på deres lighed. Formålet er at identificere homogene kunde-segmenter. Man anvender specifikt hierarkisk agglomerativ (bottom-up) clustering.

Metoden fungerer ved, at:

- Hver observation starter som sin egen klynge
- De mest lignende klynger samles iterativt
- Processen fortsætter, indtil alle observationer er samlet i en klynge
- Resultatet kan visualiseres i et dendrogram, hvor man efterfølgende vælger et passende antal klynger.

5.1.1 Anvendelse af Gower-distance

Til at måle lighed mellem kunder anvendes der Gower distance, da datasættet indeholder både numeriske og kategoriske variabler. Gower distance gør det muligt at kombinere disse datatyper i én samlet afstandsmåling.

5.1.2 Begrundelse for fravalg af en Principal Component Analysis (PCA)

Typisk anvendes Principal Component Analysis (PCA) før clustering for at reducere dimensioner og støj i data. I dette tilfælde er der dog fravalgt PCA, da metoden kun fungerer på numeriske variable og dermed ikke kan håndtere vores mixed-type datastruktur uden transformation. Derfor vurderes det, at det er mere hensigtsmæssigt at anvende Gower-distance direkte.

6 Implementering af neurale netværk og deep-learning for JP

6.1 Opbygning af et neural netværk

Det neurale netværk er i stand til at modellere meget komplekse ikke-lineære sammenhæng. Der er tale om fleksible modeller, der kan løse komplekse mønstre ved at sekventielt kombinere mange simple funktioner. Et neural netværk består af mange små enheder som kaldes “neuroner”. Disse neuroner er forbundet i tre lag: Inputlag, skjulte lag og output lag. Neurale netværk bruger også aktiverings funktioner, som gør netværket i stand til at lære komplekse mønstre (dvs. ikke lineære sammenhæng). Uden en aktiveringsfunktion, er en neural netværks model bare det samme som en lineær model. Eksempler på aktiveringsfunktioner kunne f.eks. være: Sigmoid, ReLU eller Tanh. Ved træningen af neurale netværk lærer det at justerer vægtene, så outputtet bliver korrekt. Først laves der forward pass, dvs. data sendes igennem netværket, hvilket giver et output. Derefter laves der fejlberegning, hvor man måler forskellen mellem output og det rigtige svar med en loss function. Til sidst laves der backpropagation, som gør at fejlen sendes baglæns gennem netværket for at justere vægtene på forbindelserne mellem nodes. Dette bygger på et gradient descent, hvor man finder den bedste løsning ved sekventielt at minimere fejl ved hver nye model.

6.2 Fordele og ulemper ved en Neural Netværk (NN) model

Fordelen ved en neural netværks model frem for andre mere simple klassifikationsmodeller er, at man kan fange meget komplekse mønstre. Ulemperne er, at en neural netværksmodel kræver meget data og er meget beregningstung. Dette er også hovedårsagerne til, at der ikke laves et produkt til JP, som er baseret på en NN-model. I stedet kodes der en klassifikations model i R, og laves herefter en applikation af modellen i Power BI.

6.3 Hvad der kræves af JP, for at implentere en Neural Netværk (NN) model

Skal man have en effektiv neural NN-model for JP, så kræver det et større datasæt som er bygget op over en længere periode, samt skal man have mere tid til at gøre denne model mere praktisk anvendelig. Der vælges i opgaven at kode en neural netværks model, som fungerer som en slags “skitse”, så man får vist hvilken retning JP potentielt kunne gå hen i mod, såfremt der er mere tid og et større datasæt. Der ses i opgaven, at accuracy i NN-modellen er under 50%, dvs tilfældig gætning er bedre end denne model. Dette var også forventet, pga de begrænsninger der er beskrevet.

6.4 Hvilken Neural Netværk (NN) model der anvendes i opgaven

Den neurale netværksmodel der anvendes i opgaven er en Multi-Layer Perceptron (MLP). Her er alle ledende fuldt forbundet, dvs. alle neuroner er koblet til alle i næste lag. Først smides dataene ind som input, hvorefter de føres videre til de skjulte lag og derefter kommer ud som output. Der er ingen særlig struktur i en MLP-NV-model, da alle input behandles ens.

7 Klyngeanalyse til PowerBI visualisering.

Det kan vurderes, at en implementering af nye modeller med Power BI til visualisering, som JP kan anvende, er en realistisk løsning på baggrund af JP's nuværende niveau af data modenhed. JP befinder sig med deres nuværende forretningsstruktur i fase 4 i forhold til Gartner's Data Governance Maturity Model. JP anvender i høj grad data som et brugbart værktøj til at træffe datadrevne beslutninger i deres virksomhed, og de har allerede medarbejdere, som primært arbejder med data. Den nye model bør derfor implementeres i virksomheden og integreres med Power BI for at understøtte en mere målrettet og datadrevet markedsføringsindsats. Modellen kan i praksis hjælpe JP med at identificere de abonnenter, der har størst risiko for at opsigte deres abonnement, og dermed målrette deres kampagner og kommunikation mere effektivt mod de rette segmenter. Dette giver en god mulighed for bedre ressourceallokering og øger sandsynligheden for at fastholde deres abonnenter. Samtidig er det vigtigt, at f.eks. deres Head of Analytics aktivt kan anvende Power BI som beslutningsværktøj til at træffe velinformerede og databaserede forretningsbeslutninger. For JP er det centralt at fastholde en høj standard for datakvalitet og samtidig sikre, at rapporteringen er både overskuelig og løbende opdateret, så den er optimal og understøtter en effektiv abonnementsforretning.

8 Dataklargørelse

Upload af relevante pakker.

```
pacman::p_load("tidyverse", "lubridate", "readr")
```

Indlæsning af JP datafilerne.

```
behavior <- read_csv("data/behavior.csv")
cancellation <- read_csv("data/cancellation.csv")
subscription2 <- read_csv("data/subscription_v2.csv")
```

Indlæsning og parsing af abonnementsdata

```
subscription2_clean <- subscription2 %>%
  separate(
    col = 1,
    into = c(
      "pseudo_id", "account_active_days", "subscription_cancel_date",
      "order_date", "koen", "birthdate", "usr_created", "order_trackertag",
      "permission_given_order", "permission_given_today",
      "previous_subscriptions", "previous_campaigns", "previous_trials",
      "first_campaign_day", "last_campaign_day",
      "newsletters_before_order", "newsletters_after_order"), sep = ";", convert = FALSE) %>%
  mutate(
    subscription_cancel_date = dmy(subscription_cancel_date),
    subscription_cancel_date = if_else(
      subscription_cancel_date == as.Date("3000-01-01"),
      NA_Date_,
      subscription_cancel_date),
    birthdate = dmy(birthdate),
    usr_created = dmy(usr_created),
    first_campaign_day = dmy(first_campaign_day),
    last_campaign_day = dmy(last_campaign_day),

    order_date = ymd_hms(order_date),

    account_active_days = as.numeric(account_active_days),
    previous_subscriptions = as.numeric(previous_subscriptions),
    previous_campaigns = as.numeric(previous_campaigns),
    previous_trials = as.numeric(previous_trials),
    newsletters_before_order = as.numeric(newsletters_before_order),
    newsletters_after_order = as.numeric(newsletters_after_order),

    permission_given_order = as.logical(permission_given_order),
    permission_given_today = as.logical(permission_given_today),

    koen = if_else(koen == "" | is.na(koen), "Ukendt", koen)
  )
```

Fjern dubletter.

```
subscription_renset <- subscription2_clean %>%
  group_by(pseudo_id) %>%
  slice_max(order_date, with_ties = FALSE) %>%
  ungroup()
```

```
cancellation_renset <- cancellation %>%
  group_by(pseudo_id) %>%
```

```
slice_max(expiration_date, with_ties = FALSE) %>%
ungroup()
```

Merge af subscription2- og cancellationdata

```
sub_cancel <- subscription_renset %>%
  left_join(cancellation_renset, by = "pseudo_id")
```

Beregning af abonnementslængde.

```
sub_cancel <- sub_cancel %>%
  mutate(
    end_date = if_else(
      is.na(subscription_cancel_date),
      Sys.Date(),
      subscription_cancel_date
    ),
    subscription_length_days = as.numeric(end_date - as.Date(order_date))
  )
```

Gruppering af abonnementslængde.

```
sub_cancel <- sub_cancel %>%
  mutate(
    length_group = case_when(
      subscription_length_days < 30 ~ "0-30 dage",
      subscription_length_days < 90 ~ "30-90 dage",
      subscription_length_days < 180 ~ "90-180 dage",
      subscription_length_days < 270 ~ "180-270 dage",
      subscription_length_days < 365 ~ "270-365 dage",
      TRUE ~ "365+ dage"
    )
  )
```

Filtrering af ugyldige aldre og beregning af aldersgrupper.

```
sub_cancel <- sub_cancel %>%
  filter(!is.na(birthdate)) %>%
  filter(as.numeric(difftime(as.Date(order_date), birthdate, units = "days")) / 365 >= 18) %>%
  mutate(
    age = floor(time_length(interval(birthdate, today()), "years")),
    age_group = case_when(
      age < 25 ~ "18-24",
      age < 35 ~ "25-34",
      age < 45 ~ "35-44",
      age < 55 ~ "45-54",
      age < 65 ~ "55-64",
      TRUE ~ "65+"
    )
  )
```

Oprettelse af variabler, heriblandt targetvariabler til ML-modellerne.

```
sub_cancel <- sub_cancel %>%
  mutate(
    continued_after_campaign = if_else(is.na(subscription_cancel_date) |
      subscription_cancel_date > last_campaign_day, 1, 0),

    fast_churn = if_else(
```



```

    subscription_length_days <= 3 & continued_after_campaign == 0, 1, 0),

fast_churn_converted = if_else(
  subscription_length_days <= 3 & continued_after_campaign == 1, 1, 0),

churn_10 = if_else(
  continued_after_campaign == 1 & !is.na(subscription_cancel_date) &
  as.numeric(subscription_cancel_date - last_campaign_day) <= 10, 1, 0),

account_active_days_before_campaign =
  account_active_days - as.numeric(last_campaign_day - as.Date(order_date))
)

```

Aggregering af behaviordata

```

behavior_features <- behavior %>%
  group_by(pseudo_id) %>%
  summarise(
    visits = n(),
    unique_pages = n_distinct(page_url_clean),
    restricted_views = sum(page_restricted == "yes", na.rm = TRUE),
    restricted_ratio = restricted_views / visits,
    avg_scroll = mean(scroll_depth, na.rm = TRUE),
    mobile_ratio = mean(dvce_type == "Mobile"),
    desktop_ratio = mean(dvce_type == "Computer")
  )

```

Sammenkædning af behaviordata og håndtering af manglende værdier.

```

full_data <- sub_cancel %>%
  left_join(behavior_features, by = "pseudo_id") %>%
  mutate(
    across(c(visits, unique_pages, restricted_views,
             restricted_ratio, avg_scroll, mobile_ratio,
             desktop_ratio), ~replace_na(., 0)),
    usr_created = if_else(is.na(usr_created), as.Date(order_date), usr_created),
    type = if_else(is.na(type) & !is.na(subscription_cancel_date), "Ukendt", type),
    reason = if_else(is.na(reason) & !is.na(subscription_cancel_date), "Ukendt", reason),
    expiration_date = if_else(
      is.na(expiration_date) & !is.na(subscription_cancel_date),
      subscription_cancel_date,
      expiration_date
    )
  )
)

```

Konstruktion af adfærdsvariable til klyngeanalyse.

```
behavior_agg <- behavior %>%
  mutate(
    er_artikel = str_detect(page_url_clean, "ECE\\d{8}"),
    er_restricted = page_restricted == "yes",
    dato = as.Date(dt),
    sektion = case_when(
      str_detect(page_url_clean, "/indland/") ~ "indland",
      str_detect(page_url_clean, "/international/") ~ "international",
      str_detect(page_url_clean, "/sport/") ~ "sport",
      str_detect(page_url_clean, "/erhverv/") ~ "erhverv",
      str_detect(page_url_clean, "/kultur/") ~ "kultur",
      str_detect(page_url_clean, "/livsstil/") ~ "livsstil",
      str_detect(page_url_clean, "/debat/") ~ "debat",
      str_detect(page_url_clean, "/politik/") ~ "politik",
      str_detect(page_url_clean, "/rejser/") ~ "rejser",
      str_detect(page_url_clean, "/biler/") ~ "biler",
      page_url_clean == "https://jyllands-posten.dk/" ~ "forside",
      TRUE ~ "andet")) %>%
  group_by(pseudo_id) %>%
  summarise(
    antal_sidevisninger = n(),
    antal_unikke_dage = n_distinct(dato),
    antal_unikke_sider = n_distinct(page_url_clean),
    antal_artikler = sum(er_artikel),
    gns_scroll = mean(scroll_depth, na.rm = TRUE),
    andel_restricted = mean(er_restricted),

    er_mobil_primær = {
      t <- table(dvce_type)
      if (length(t) == 0) NA_integer_
      else as.integer(names(which.max(t)) == "Mobile")
    },

    antal_devices = n_distinct(dvce_type),

    andel_search = mean(refr_medium == "search"),
    andel_internal = mean(refr_medium == "internal"),
    andel_social = mean(refr_medium == "social"),

    andel_indland = mean(sektion == "indland"),
    andel_international = mean(sektion == "international"),
    andel_sport = mean(sektion == "sport"),
    andel_erhverv = mean(sektion == "erhverv"),
    andel_kultur = mean(sektion == "kultur"),
    andel_livsstil = mean(sektion == "livsstil"),
    andel_debat = mean(sektion == "debat"),
    andel_politik = mean(sektion == "politik"),
    andel_rejser = mean(sektion == "rejser"),
    andel_forside = mean(sektion == "forside"),
    andel_biler = mean(sektion == "biler"),
    andel_andet = mean(sektion == "andet"),

    gns_sider_pr_dag = n() / n_distinct(dato),
```

```
.groups = "drop") %>%  
mutate(across(everything(), ~replace_na(.x, 0)))
```

Gem det rensede datasæt.

```
saveRDS(behavior_agg, "data/datasæt_konstruerede_variabler.rds")  
saveRDS(full_data, "data/renset_datasæt.rds")
```

```
full_data %>%  
  mutate(across(where(is.Date), ~ as.character(.x))) %>%  
  mutate(across(everything(), ~ ifelse(is.na(.x), "", .x))) %>%  
  mutate(across(where(is.numeric), ~ round(.x, 4))) %>%  
  write.table("data/renset_data.csv",  
             sep = ";", dec = ",", row.names = FALSE, quote = FALSE)
```

9 Modellering - Klyngeanalyse

9.1 Dataklargøring til modellering

Upload af relevante pakker.

```
pacman::p_load("tidyverse", "cluster", "janitor")
```

Datasættene indlæses.

```
model_data <- readRDS("data/renset_datasæt.rds")
behavior_agg <- readRDS("data/datasæt_konstruerede_variabler.rds")
```

Join af adfærdsvariabler med modeldata.

```
model_data <- model_data %>%
  left_join(behavior_agg, by = "pseudo_id")
```

Udvælgelse af variabler til algoritmen.

```
cluster_vars_raw <- model_data %>%
  select(any_of(c(
    "pseudo_id",
    # Demografi
    "koen", "age_group", "age",
    # Historik
    "previous_subscriptions", "previous_campaigns", "previous_trials",
    # Adfærd
    "antal_sidevisninger", "antal_unikke_sider", "gns_sider_pr_dag",
    "andel_restricted", "gns_scroll",
    # Platform
    "er_mobil_primær", "antal_devices",
    # Content
    "andel_search", "andel_internal", "andel_social",
    "andel_indland", "andel_kultur", "andel_sport",
    "andel_erhverv", "andel_forside"
  )))
```

Vi har nu udvalgt de variabler, der skal anvendes til vores klyngeanalyse-algoritme.

Klargøring og transformation af variabler.

```
cluster_vars <- cluster_vars_raw %>%
  drop_na() %>%
  mutate(
    across(where(is.character), as.factor),
    across(where(is.logical), as.factor),
    # Transformationer af skæve variabler
    antal_sidevisninger = log1p(antal_sidevisninger),
    gns_sider_pr_dag = log1p(gns_sider_pr_dag)
  )
```

9.2 Klyngeanalyse

Beregning af Gower-distance.


```
gower_dist <- daisy(cluster_vars %>% select(-pseudo_id), metric = "gower")
```

Warning in daisy(cluster_vars %>% select(-pseudo_id), metric = "gower"): binary variable(s) 12 treated as interval scaled

Der anvendes Gower-distance, da datasættet indeholder både numeriske og kategoriske variabler. Gower-distance gør det muligt, at kombinere mixed-data i en samlet afstandsmåling. Dette er grunden til der ikke er kørt en Principal Component Analysis (PCA), da den kræver numeriske, kontinuerte variabler. PCA bruger i praksis Euklidisk-distance, fordi den bygger på kovariansmatricen, som forudsætter lineære sammenhænge, og dermed ikke er i stand til at håndtere kategoriske variabler.

Hierarkisk clustering og dendrogram.

```
hc <- hclust(gower_dist, method = "ward.D2")
plot(hc, main = "Hierarkisk clustering - kundetyper")
rect.hclust(hc, k = 4, border = "red")
```



Der køres en hierarkisk agglomerativ klyngeanalyse, hvor der først beregnes en Gower-distance mellem alle observationer. Derefter anvendes hclust() med Ward.D2-metoden til at opbygge et dendrogram, som viser, hvordan observationerne gradvist grupperes. Til sidst markeres fire klynger i plottet med rect.hclust(), som skærer dendrogrammet på det niveau, der svarer til fire klynger.

Tilføjelse af klyngetags.

```
k <- 4
cluster_vars <- cluster_vars %>%
  mutate(cluster = factor(cutree(hc, k = k)))
```

Join af klyngetags til datasættet .

```
model_data <- model_data %>%
  left_join(cluster_vars %>% select(pseudo_id, cluster) %>% distinct(),
    by = "pseudo_id")
```

Fjernelse af observationer uden klynge.

```
model_data_clean <- model_data %>% filter(!is.na(cluster))
```

9.3 Klyngeprofiler

Oprettelse af klyngeprofil.

```
cluster_profile <- model_data_clean %>%
  group_by(cluster) %>%
  summarise(
    across(where(is.numeric), ~ round(mean(.x, na.rm = TRUE), 2)),
    across(where(is.character), ~ names(sort(table(.), decreasing = TRUE))[1]),
    .groups = "drop"
  )
```

Forklaring af klyngerne:

Klynge 1 – Moderat engagerede med forhøjet churn

- Moderat aktivitetsniveau målt ved antal sidevisninger og unikke sider
- Relativt høj brug af restricted indhold
- Primært desktop-baseret brug
- Moderat aldersprofil (ca. 50–55 år)
- Relativt høj churn-rate sammenlignet med øvrige klynger
- Læser primært indland og forside

Klynge 2 – Lavt engagerede mobilbrugere med svag fastholdelse

- Lav aktivitet med få besøg, begrænset antal sidevisninger og lav scroll-dybde
- Overvejende mobilbrug (meget høj mobilandel)
- Relativt lav retention og tegn på ustabil abonnementsadfærd
- Kortere abonnementsperioder
- Fokus på forside og indlandsstof

Klynge 3 – Højt engagerede læsere med stabil fastholdelse

- Meget højt aktivitetsniveau med mange sidevisninger, artikler og besøg
- Lavere gennemsnitlig scroll-dybde, hvilket indikerer bredere frem for dybere læsning
- Blandet device-brug (mobil og desktop)
- Relativt høj retention og lav churn-rate
- Bred læseadfærd på tværs af indholdskategorier
- Moderat aldersprofil

Klynge 4 – Loyale abonnenter med stabil adfærd

- Højt aktivitetsniveau og relativt mange sidevisninger
- Primært desktop-baseret brug
- Relativt høj retention og lav churn-rate
- Stabil abonnementsadfærd over tid
- Bred, men mindre intensiv læseprofil end klynge 3

Klynge 2 har den højeste churn-risiko, mens klynge 4 har den laveste. Der er en tydelig sammenhæng mellem aktivitet og churn. Det kan ses, at høj aktivitet = lav churn, og lav aktivitet = høj churn. Brugere, der læser dybere og mere redaktionelt indhold (fx artikler, indland, sport, analyser), har markant lavere churn end dem, der primært læser mere “overfladiske” kategorier som økonomi og udland.

Outcome profilering per klynge.

```
cluster_outcomes <- model_data_clean %>%
  group_by(cluster) %>%
  summarise(
    n = n(),
    fast_churn_rate = mean(fast_churn, na.rm = TRUE),
    retention_rate = mean(continued_after_campaign, na.rm = TRUE),
    avg_subscription_length = mean(subscription_length_days, na.rm = TRUE),
    .groups = "drop"
  )
```


Klynge 2 har den laveste fast churn-rat, hvilket gør den til den mindst risikable klynge ift hurtig churn. Klynge 4 og klynge 3 er også ret stabile, men ikke helt på niveau med klynge 2. Klynge 1 er den mest churn-risikable med den højeste fast churn-rate.

9.4 Visualisering

MDS visualisering af klynger

```
mds <- cmdscale(gower_dist, k = 2, eig = TRUE)
mds_df <- data.frame(
  Dim1 = mds$points[,1],
  Dim2 = mds$points[,2],
  cluster = cluster_vars$cluster
)

ggplot(mds_df, aes(Dim1, Dim2, color = cluster)) +
  geom_point(alpha = 0.7, size = 2) +
  theme_minimal() +
  labs(title = "MDS-visualisering af Gower-baserede klynger",
       x = "Dimension 1", y = "Dimension 2")
```



MDS-visualiseringen gør det tydeligt, at klynge 1 ligger længst fra de andre klynger. Det er også den klynge, der har den højeste fast-churn-rate og dermed den kundegruppe der har den største churn-risiko. De øvrige klynger ligger tættere på hinanden. Visualiseringen bekræfter derfor, at klynge 1 kræver særligt fokus i retention-indsatser, hvis JP skal øge deres omsætning. Dette er fordi de både er mest forskellige fra de loyale

segmenter og samtidig de mest tilbøjelige til at churne.

9.5 Gem som CSV-filer til Power BI

Eksport af resultater til Power BI

```
write.table(cluster_profile, "data/klynge_profil.csv",  
            sep = ";", dec = ",", row.names = FALSE, quote = FALSE)  
  
write.table(model_data_clean, "data/model_data_med_klynger.csv",  
            sep = ";", dec = ",", row.names = FALSE, quote = FALSE)  
  
write.table(mds_df, "data/mds_coordinates.csv",  
            sep = ";", dec = ",", row.names = FALSE, quote = FALSE)
```


10 Modellering - Churn i kampagnen

10.1 Dataklargøring til modellering

Upload af relevante pakker.

```
pacman::p_load("tidyverse", "lubridate", "caret", "randomForest", "xgboost", "pROC")
```

Indlæsning af JP-data.

```
model_data_raw <- read_rds("data/renset_datasæt.rds")
```

Datoformatering.

```
model_data <- model_data_raw %>%  
  mutate(  
    order_date = as.Date(order_date),  
    usr_created = as.Date(usr_created),  
    subscription_cancel_date = as.Date(subscription_cancel_date),  
    birthdate = as.Date(birthdate)  
  )
```

Konvertering af target variabel til factor.

```
model_data <- model_data %>%  
  mutate(  
    continued_after_campaign = factor(  
      continued_after_campaign,  
      levels = c(0, 1),  
      labels = c("No", "Yes"))
```

Feature engineering. Konstruktion af nye prædiktorer (x-variabler).

```
model_data <- model_data %>%  
  mutate(  
    days_since_user_created = as.numeric(order_date - usr_created),  
    age_at_order = as.numeric(difftime(order_date, birthdate, units = "days")) / 365,  
    permission_user = ifelse(permission_given_order == TRUE, 1, 0),  
    total_previous_engagement = previous_subscriptions + previous_campaigns + previous_trials,  
    has_previous_subscriptions = ifelse(previous_subscriptions > 0, 1, 0),  
    engagement_score = (visits * 0.4) + (unique_pages * 0.3) + (avg_scroll * 0.3),  
    age_engagement_interaction = age_at_order * engagement_score,  
    permission_engagement = permission_user * engagement_score  
  ) %>%  
  drop_na()
```

Der er lavet feature engineering for at forbedre modellens evne til at lære mønstre, der ellers ville være skjulte i de oprindelige data. De nye variabler, der er skabt her, giver modellen mere meningsfuld information og gør den bedre til at forudsige, om en kunde fortsætter churner under kampagnen.

Fjernelse af leakage-variabler samt overflødige variabler.

```
model_data <- model_data %>%  
  select(  
    -subscription_cancel_date,  
    -end_date,  
    -expiration_date,  
    -newsletters_after_order,  
    -fast_churn,  
    -subscription_length_days,  
    -length_group,
```

```

    -type,
    -order_date,
    -usr_created,
    -birthdate,
    -first_campaign_day,
    -last_campaign_day,
    -account_active_days,
    -churn_10,
    -order_trackertag,
    -reason,
    -permission_given_today,
    -age
  )

```

Leakage-variablerne er nu fjernet. Det er vigtigt, fordi de indeholder information, som kun er kendt efter kampagneperioden er slut. Hvis leakage variabler bliver i datasættet, så lærer modellen at forudsige churn ud fra fremtidsinformation, som den ikke vil have adgang til, når den skal lave en reel forudsigelse. Dette betyder, at modellen bliver urealistisk god under træning, men ubrugelig i praksis.

`pseudo_id` gemmes i en separat vektor inden variabelen fjernes fra datasættet, da den ikke må indgå som prædiktør i modellerne, men skal bruges senere til at knytte churn sandsynligheder tilbage til de specifikke kunder.

```

pseudo_ids <- model_data$pseudo_id
model_data <- model_data %>% select(-pseudo_id)

```

Sikrer reproducerbarhed med `set.seed`.

```
set.seed(47)
```

Trænings- og testopsplitning (80/20).

```

train_index <- createDataPartition(model_data$continued_after_campaign, p = 0.8, list = FALSE)
train_data <- model_data[train_index, ]
test_data <- model_data[-train_index, ]

```

Gem pseudo ID'er for testdata.

```
test_ids <- pseudo_ids[-train_index]
```

10.2 Håndtering korrelerede variabler

Kontrollerer for højt-korrelerede variabler.

```

cor_matrix <- cor(train_data %>% select(where(is.numeric)))
high_cor <- which(abs(cor_matrix) > 0.95 & cor_matrix != 1, arr.ind = TRUE)

```

Identifikation af variabler til fjernelse.

```
findLinearCombos(train_data %>% select(where(is.numeric)))
```

```

$linearCombos
$linearCombos[[1]]
[1] 17 1 2 3

```

```

$linearCombos[[2]]
[1] 19 7 8 11

```

```
$remove
```

```
[1] 17 19
```

Udtræk af numeriske variabler.

```
num_vars <- train_data %>% select(where(is.numeric))
```

Lineært afhængige variabler fjernes.

```
vars_to_remove <- colnames(num_vars)[c(17, 19)]
```

Oprettelse af datasæt til logistisk regression uden lineært afhængige variabler.

```
train_data_log_reg <- train_data %>% select(-all_of(vars_to_remove))
test_data_log_reg <- test_data %>% select(-all_of(vars_to_remove))
```

Verifikation af lineær uafhængigheder.

```
findLinearCombos(train_data_log_reg %>% select(where(is.numeric)))
```

```
$linearCombos
list()
```

```
$remove
NULL
```

De lineære afhængige variabler er nu fjernet. Lineære afhængigheder er et problem for den logistiske regressionsmodel, fordi modellen ikke kan skelne mellem variabler, der i praksis indeholder den samme information. Det er dog ikke et problem for de træbaseret metoder der anvendes (Random Forest og XGBoost), fordi træbaseret modeller kun vælger en variabel ad gangen. Når et beslutningstræ splitter data, vælger det den variabel, der giver den bedste forbedring i fx Gini eller entropi. Hvis to variabler indeholder den samme information, så vælger træet bare et af dem, og ignorerer den anden.

```
set.seed(47)
```

10.3 Opsætning af cross-validation kontrol til modevaluering.

```
cv_ctrl <- trainControl(
  method = "cv",
  number = 5,
  classProbs = TRUE,
  summaryFunction = twoClassSummary
)
```

Der er nu opsat en cross-validation kontrol til modevaluering. Dette skal afgør hvor gode modellerne er til at præstere på nye ukendte data. Hvis modellen klarer sig godt på træningsdataene, men ikke testdataene, så betyder det, at modellen overfitter, dvs. opsamler alt muligt unødvendig “støj” information.

10.4 Logistisk Regression

Der laves en Logistisk Regression model, da den skal bruges som en “baseline-model”, som anvendes til at sammenligne alle de andre modeller med. Dette giver en direkte indsigt i den sammenhæng der er i dataene.

Træning af logistisk regression med cross-validation.

```
log_cv <- train(
  continued_after_campaign ~ .,
  data = train_data_log_reg,
  method = "glm",
  family = binomial,
  trControl = cv_ctrl,
  metric = "ROC"
)
```

Træning af endelig logistisk regressionsmodel

```
log_model <- glm(
  continued_after_campaign ~ .,
```

```
data = train_data_log_reg,  
family = binomial  
)
```

Forudsigelse af sandsynligheder på testdata.

```
log_prob <- predict(log_model, test_data_log_reg, type = "response")
```

Beregning af ROC-kurve.

```
roc_log <- roc(test_data_log_reg$continued_after_campaign, log_prob)
```

Bestemmelse af optimalt threshold via Youden's J.

```
cut_log <- as.numeric(coords(roc_log, "best", ret = "threshold"))
```

Konvertering af sandsynligheder til klasser.

```
log_pred <- ifelse(log_prob > cut_log, "Yes", "No") %>%  
  factor(levels = c("No", "Yes"))
```

Beregning af confusion matrix

```
cm_log <- confusionMatrix(log_pred, test_data$continued_after_campaign)
```

10.5 Random Forest

Random Forest anvendes for at fange mere komplekse mønstre. Dette gør at modellens performance forbedres i forhold til den logistiske regressionsmodel, samt at der kan afdækkes interaktioner mellem variablerne.

```
set.seed(47)
```

Træning af Random Forest med cross-validation.

```
rf_cv <- train(  
  continued_after_campaign ~ .,  
  data = train_data,  
  method = "rf",  
  trControl = cv_ctrl,  
  metric = "ROC",  
  tuneLength = 5  
)
```

Træning af endelig Random Forest model.

```
rf_model <- randomForest(  
  continued_after_campaign ~ .,  
  data = train_data,  
  ntree = 500,  
  mtry = floor(sqrt(ncol(train_data) - 1)),  
  importance = TRUE  
)
```

Forudsigelse af sandsynligheder på testdata.

```
rf_prob <- predict(rf_model, test_data, type = "prob")[,2]
```

Beregning af ROC-kurve.

```
roc_rf <- roc(test_data$continued_after_campaign, rf_prob)
```

Bestemmelse af optimalt threshold via Youden's J.

```
cut_rf <- as.numeric(coords(roc_rf, "best", ret = "threshold"))
```

Konvertering af sandsynligheder til klasser.

```
rf_pred <- ifelse(rf_prob > cut_rf, "Yes", "No") %>%  
  factor(levels = c("No", "Yes"))
```

Beregning af confusion matrix.

```
cm_rf <- confusionMatrix(rf_pred, test_data$continued_after_campaign)
```

10.6 XGBoost

XGBoost har en meget høj præcision, og er meget effektiv til at håndtere komplekse datastrukturer. Boosting fungerer ved at bygge modeller sekventielt, hvor hver nye model retter fejlene fra de forrige model. Derfor er en boosting-model godt egnet til en case med churn-prædiktion, og der er en hypotese om, at den vil klare sig bedst af de tre valgte klassifikationsmodeller.

Konvertering til numerisk matrix.

```
full_matrix <- model.matrix(continued_after_campaign ~ . - 1, data = model_data)
```

Opdeling af matrix i trænings- og testdata.

```
train_matrix <- full_matrix[train_index, ]  
test_matrix  <- full_matrix[-train_index, ]
```

Udtræk af target-variabel for træningsdata.

```
y_train <- model_data$continued_after_campaign[train_index]
```

Oprettelse af DMatrix til XGBoost.

```
dtrain <- xgb.DMatrix(data = train_matrix, label = as.numeric(y_train) - 1)  
dtest  <- xgb.DMatrix(data = test_matrix,  label = as.numeric(model_data$continued_after_campaign[-train_index]) - 1)  
  
set.seed(47)
```

Cross-validation af XGBoost.

```
xgb_cv2 <- xgb.cv(  
  data = dtrain,  
  nrounds = 300,  
  params = list(  
    max_depth = 4,  
    eta = 0.05,  
    subsample = 0.8,  
    colsample_bytree = 0.8,  
    objective = "binary:logistic",  
    eval_metric = "auc"  
  ),  
  nfold = 5,  
  verbose = 0  
)
```

Træning af endelig XGBoost model.

```
xgb_model <- xgb.train(  
  data = dtrain,  
  nrounds = 300,  
  params = list(  
    max_depth = 4,  
    eta = 0.05,  
    subsample = 0.8,  
    colsample_bytree = 0.8,  
    objective = "binary:logistic",  
    eval_metric = "auc"  
  )  
)
```

Forudsigelse af sandsynligheder på testdata.


```
xgb_prob <- predict(xgb_model, dtest)
```

Beregning af ROC-kurve.

```
roc_xgb <- roc(test_data$continued_after_campaign, xgb_prob)
```

Bestemmelse af optimalt threshold via Youden's J.

```
cut_xgb <- as.numeric(coords(roc_xgb, "best", ret = "threshold"))
```

Konvertering af sandsynligheder til klasser.

```
xgb_pred <- ifelse(xgb_prob > cut_xgb, "Yes", "No") %>%  
  factor(levels = c("No", "Yes"))
```

Beregning af confusion matrix.

```
cm_xgb <- confusionMatrix(xgb_pred, test_data$continued_after_campaign)
```

10.7 Tabel over mest risikable kunder

Oprettelse af risikotibble.

```
risk_list <- tibble(  
  pseudo_id = test_ids,  
  churn_probability = xgb_prob,  
  predicted_class = xgb_pred  
)
```

Sortering efter churn sandsynlighed.

```
risk_list_sorted <- risk_list %>%  
  arrange(desc(churn_probability))
```

Opbygning af endelig risikotabel.

```
risk_table <- risk_list_sorted %>%  
  mutate(  
    churn_risk_pct = round(churn_probability * 100, 1),  
    risk_group = case_when(  
      churn_probability >= 0.75 ~ "Høj risiko",  
      churn_probability >= 0.50 ~ "Middel risiko",  
      TRUE ~ "Lav risiko")) %>%  
  select(  
    pseudo_id,  
    churn_risk_pct,  
    predicted_class,  
    risk_group)
```

10.8 Økonomisk analyse af churn-kampagne

Definition af listepris (der vælges standardprisen fra JP's hjemmeside).

```
JP_pris <- 199
```

Filtrering af højrisiko-kunder.

```
high_risk <- risk_list_sorted %>%  
  filter(churn_probability > 0.75)
```

Optælling af højrisiko-kunder.

```
n_high_risk <- nrow(high_risk)
```

Beregning af økonomisk værdi for tre scenarier.

```
uplift_5 <- 0.05  
saved_5 <- n_high_risk * uplift_5  
value_3m_5 <- saved_5 * JP_pris * 3  
value_6m_5 <- saved_5 * JP_pris * 6  
value_12m_5 <- saved_5 * JP_pris * 12
```

```
uplift_15 <- 0.15  
saved_15 <- n_high_risk * uplift_15  
value_3m_15 <- saved_15 * JP_pris * 3  
value_6m_15 <- saved_15 * JP_pris * 6  
value_12m_15 <- saved_15 * JP_pris * 12
```

```
uplift_25 <- 0.25  
saved_25 <- n_high_risk * uplift_25  
value_3m_25 <- saved_25 * JP_pris * 3  
value_6m_25 <- saved_25 * JP_pris * 6  
value_12m_25 <- saved_25 * JP_pris * 12
```

Oprettelse af økonomisk overblikstabel.

```
economy_table <- tibble(  
  scenario = c("5% (Worst case)", "15% (Realistisk)", "25% (Optimistisk)"),  
  højrisiko_kunder = n_high_risk,  
  reddede_kunder = round(c(saved_5, saved_15, saved_25)),  
  besparelse_3m = round(c(value_3m_5, value_3m_15, value_3m_25)),  
  besparelse_6m = round(c(value_6m_5, value_6m_15, value_6m_25)),  
  besparelse_12m = round(c(value_12m_5, value_12m_15, value_12m_25))  
)
```

10.9 Sammenligning af modeller

Udtræk af AUC-værdier.

```
auc_log <- as.numeric(pROC::auc(roc_log))
auc_rf  <- as.numeric(pROC::auc(roc_rf))
auc_xgb <- as.numeric(pROC::auc(roc_xgb))
```

Oprettelse af modelsammenligningstabel.

```
model_sammenligning <- tibble(
  Model      = c("Logistisk regression", "Random Forest", "XGBoost"),
  AUC        = round(c(auc_log, auc_rf, auc_xgb), 4),
  Accuracy   = round(c(
    cm_log$overall["Accuracy"],
    cm_rf$overall["Accuracy"],
    cm_xgb$overall["Accuracy"]
  ), 4),
  Sensitivity = round(c(
    cm_log$byClass["Sensitivity"],
    cm_rf$byClass["Sensitivity"],
    cm_xgb$byClass["Sensitivity"]
  ), 4),
  Specificity = round(c(
    cm_log$byClass["Specificity"],
    cm_rf$byClass["Specificity"],
    cm_xgb$byClass["Specificity"]
  ), 4)
)


knitr::kable(
  model_sammenligning,
  caption = "Sammenligning af modeller - Model 1 (churn ved kampagneslut)",
  col.names = c("Model", "AUC", "Accuracy", "Sensitivitet", "Specificitet")
)
```

Tabel 1: Sammenligning af modeller — Model 1 (churn ved kampagneslut)

Model	AUC	Accuracy	Sensitivitet	Specificitet
Logistisk regression	0,6714	0,6524	0,4808	0,8208
Random Forest	0,7710	0,7048	0,6731	0,7358
XGBoost	0,7861	0,7190	0,6923	0,7453

Visualisering af ROC-kurver.

```
plot(roc_log, col = "steelblue", lwd = 2,
     main = "ROC-kurver - Model 1 (churn ved kampagneslut)")
plot(roc_rf, col = "darkgreen", lwd = 2, add = TRUE)
plot(roc_xgb, col = "firebrick", lwd = 2, add = TRUE)
legend("bottomright",
     legend = c(
       paste0("Logistisk regression (AUC = ", round(auc_log, 3), ")"),
       paste0("Random Forest (AUC = ", round(auc_rf, 3), ")"),
       paste0("XGBoost (AUC = ", round(auc_xgb, 3), ")")
     ),
     col = c("steelblue", "darkgreen", "firebrick"),
     lwd = 2)
```



Udtræk af variabelvigtighed fra Random Forest.


```
rf_imp <- importance(rf_model) %>%
  as.data.frame() %>%
  rownames_to_column("variabel") %>%
  arrange(desc(MeanDecreaseGini))
```

Visualisering af variabelvigtighed i Random Forest modellen.

```
rf_imp %>%
  slice_head(n = 15) %>%
  ggplot(aes(x = reorder(variabel, MeanDecreaseGini), y = MeanDecreaseGini)) +
  geom_col(fill = "darkgreen", alpha = 0.8) +
  coord_flip() +
  labs(
    title = "Variabelvigtighed - Random Forest (Model 1)",
    subtitle = "MeanDecreaseGini: hvor meget variabelen reducerer usikkerhed på tværs af træer",
    x = NULL,
    y = "MeanDecreaseGini"
  ) +
  theme_minimal()
```

Variabelvigtighed — Random Forest (M)

MeanDecreaseGini: hvor meget variablen redu



Udtræk af variabelvigtighed fra XGBoost.


```
xgb_imp <- xgb.importance(model = xgb_model) %>%
  as_tibble()
```

Visualisering af variabelvigtighed i XGBoost modellen.

```
xgb_imp %>%
  slice_head(n = 15) %>%
  ggplot(aes(x = reorder(Feature, Gain), y = Gain)) +
  geom_col(fill = "firebrick", alpha = 0.8) +
  coord_flip() +
  labs(
    title = "Variabelvigtighed - XGBoost (Model 1)",
    subtitle = "Gain: hvor meget hver variabel forbedrer modellens præcision",
    x = NULL,
    y = "Gain"
  ) +
  theme_minimal()
```

Variabelvigtighed — XGBoost (Model 1)

Gain: hvor meget hver variabel forbedrer mode



10.10 Cross-validation sammenligning

Udtræk af cross-validation resultater fra logistisk regression.

```
log_cv_results <- log_cv$results %>%
  select(ROC, Sens, Spec) %>%
  slice(which.max(ROC)) %>%
  mutate(Model = "Logistisk regression")
```

Udtræk af cross-validation resultater fra Random Forest.

```
rf_cv_results <- rf_cv$results %>%
  select(ROC, Sens, Spec) %>%
  slice(which.max(ROC)) %>%
  mutate(Model = "Random Forest")
```

Udtræk af cross-validation resultater fra XGBoost.

```
xgb_cv_results <- tibble(
  Model = "XGBoost",
  ROC = max(xgb_cv2$evaluation_log$test_auc_mean),
  Sens = NA, # xgb.cv giver ikke Sens/Spec direkte
  Spec = NA
)
```

Sammenstilling af cross-validation resultater.

```
cv_sammenligning <- bind_rows(
  log_cv_results,
  rf_cv_results,
  xgb_cv_results) %>%
  select(Model, ROC, Sens, Spec)
```

Vi har udviklet en klassifikationsmodel, der forudsiger, om en kunde fortsætter efter kampagneperioden (churn eller ej). Vi har brugt korrekt feature engineering og fjernet dataleakage, og lavet tre forskellige klassifikationsmodeller. XGBoost modellen opnår den højeste AUC på 78,5% og dermed den bedste balance mellem sensitivitet og specificitet, hvor den finder 75,0% af churnerne og 70,8% af de kunder der fortsætter. Random Forest har

en AUC på 77,1% og finder 94,2% af churnerne, men kun 44,3% af ikke-churnerne — en ubalance der gør den mindre egnet. Logistisk regression er den svageste model med AUC på 66,9%. Vi har valgt XGBoost da den har den bedste balance mellem sensitivitet og specificitet.

10.11 Gem som CSV-filer til Power BI

```
risk_list %>%
  mutate(across(where(is.numeric), ~ round(.x, 4))) %>%
  write.table("data/risiko_liste.csv",
             sep = ";", dec = ",", row.names = FALSE, quote = FALSE)

write.csv(economy_table, "data/økonomisk_besparselse.csv", row.names = FALSE)

xgb_imp %>%
  mutate(across(where(is.numeric), ~ round(.x, 4))) %>%
  write.table("data/xgb_variabel_vigtighed.csv",
             sep = ";", dec = ",", row.names = FALSE, quote = FALSE)

model_data_raw %>%
  select(pseudo_id, continued_after_campaign, koen, age, age_group) %>%
  write.table("data/kampagne_oversigt.csv",
             sep = ";", dec = ",", row.names = FALSE, quote = FALSE)
```

11 Modellering - Churn kort tid efter kampagnen

11.1 Dataklargøring til modellering

Upload af relevante pakker.

```
pacman::p_load("tidyverse", "lubridate", "caret", "pROC", "randomForest", "xgboost")
```

Indlæsning af JP-data.

```
model_data <- read_rds("data/renset_datasæt.rds")
```

Filtrering til kunder der fortsætter efter kampagnen.

```
model2_data <- model_data %>%
  filter(continued_after_campaign == 1)
```

Gem pseudo ID'er separat for hele datasættet.

```
model2_ids <- model2_data$pseudo_id
```

Konvertering af target variabelen til en factor.

```
model2_data <- model2_data %>%
  mutate(
    churn_10 = factor(
      churn_10,
      levels = c(0, 1),
      labels = c("No", "Yes")
    )
  )
```

Feature engineering. Konstruktion af nye prædiktorer (x-variabler).

```
model2_data <- model2_data %>%
  mutate(
    days_since_user_created = as.numeric(difftime(order_date, usr_created, units = "days")),
```



```
age_at_order = as.numeric(difftime(order_date, birthdate, units = "days")) / 365
)
```

Udvælgelse af variabler til modellering.

```
model2_data <- model2_data %>%
  select(
    # Demografiske
    koen,
    age_at_order,

    # Abonnementshistorik
    previous_subscriptions,
    previous_campaigns,
    previous_trials,
    account_active_days_before_campaign,

    # Permission og nyhedsbreve
    permission_given_order,
    newsletters_before_order,
    newsletters_after_order,

    # Adfærd de første 30 dage
    visits,
    unique_pages,
    restricted_views,
    restricted_ratio,
    avg_scroll,
    mobile_ratio,
    desktop_ratio,

    # Feature engineered
    days_since_user_created,

    # Target
    churn_10
  )
```

Sikrer reproducerbarhed med set.seed.

```
set.seed(47)
```

Trænings- og testopsplitning (80/20).

```
train_index2 <- createDataPartition(model2_data$churn_10, p = 0.8, list = FALSE)
train_data2 <- model2_data[train_index2, ]
test_data2 <- model2_data[-train_index2, ]
```

11.2 Håndtering korrelerede variabler

Kontrol af højt korrelerede variabler.

```
cor_matrix2 <- cor(train_data2 %>% select(where(is.numeric)))
high_cor2 <- which(abs(cor_matrix2) > 0.95 & cor_matrix2 != 1, arr.ind = TRUE)
```

Identifikation af lineært afhængige variabler.

```
findLinearCombos(train_data2 %>% select(where(is.numeric)))
```

```
$linearCombos  
list()
```

```
$remove  
NULL
```

Der er ikke identificeret lineære afhængige variabler.

11.3 Opsætning af cross-validation kontrol til modevaluering.

```
set.seed(47)
```

Definition af cross-validation parametre.

```
cv_ctrl2 <- trainControl(  
  method = "cv",  
  number = 5,  
  classProbs = TRUE,  
  summaryFunction = twoClassSummary  
)
```

11.4 Logistisk Regression

Årsagen der er valgt en lineær regression model til at forudsige churn kort tid efter kampagnen, er den samme årsag som ved model 1.

Træning af logistisk regression med cross-validation.

```
log_cv2 <- train(  
  churn_10 ~ .,  
  data = train_data2,  
  method = "glm",  
  family = binomial,  
  trControl = cv_ctrl2,  
  metric = "ROC"  
)
```

Træning af endelig logistisk regressionsmodel.

```
log_model2 <- glm(churn_10 ~ ., data = train_data2, family = binomial)
```

Forudsigelse af sandsynligheder på testdata.

```
log_prob2 <- predict(log_model2, test_data2, type = "response")
```

Beregning af ROC-kurve.

```
roc_log2 <- roc(test_data2$churn_10, log_prob2)
```

Setting levels: control = No, case = Yes

Setting direction: controls < cases

Bestemmelse af optimalt threshold via Youden's J.

```
cut_log2 <- as.numeric(coords(roc_log2, "best", ret = "threshold"))
```

Konvertering af sandsynligheder til klasser og beregning af confusion matrix.

```
log_pred2 <- ifelse(log_prob2 > cut_log2, "Yes", "No") %>%  
  factor(levels = c("No", "Yes"))
```

```
cm_log2 <- confusionMatrix(log_pred2, test_data2$churn_10)
```

11.5 Random Forest

Årsagen der er valgt en Random Forest model til at forudsige churn kort tid efter kampagnen, er den samme årsag som ved model 1.

```
set.seed(47)
```

Træning af Random Forest med cross-validation.

```
rf_cv2 <- train(  
  churn_10 ~ .,  
  data = train_data2,  
  method = "rf",  
  trControl = cv_ctrl2,  
  metric = "ROC",  
  tuneLength = 5  
)
```

Træning af endelig Random Forest model.

```
rf_model2 <- randomForest(  
  churn_10 ~ .,  
  data = train_data2,  
  ntree = 500,  
  mtry = floor(sqrt(ncol(train_data2) - 1)),  
  importance = TRUE  
)
```

Forudsigelse af sandsynligheder på testdata.

```
rf_prob2 <- predict(rf_model2, test_data2, type = "prob")[,2]
```

Beregning af ROC-kurve.

```
roc_rf2 <- roc(test_data2$churn_10, rf_prob2)
```

Setting levels: control = No, case = Yes

Setting direction: controls < cases

Bestemmelse af optimalt threshold via Youden's J.

```
cut_rf2 <- as.numeric(coords(roc_rf2, "best", ret = "threshold"))
```

Konvertering af sandsynligheder til klasser.

```
rf_pred2 <- ifelse(rf_prob2 > cut_rf2, "Yes", "No") %>%  
  factor(levels = c("No", "Yes"))
```

Beregning af confusion matrix.

```
cm_rf2 <- confusionMatrix(rf_pred2, test_data2$churn_10)
```

11.6 XGBoost

Årsagen der er valgt en XGBoost model til at forudsige churn kort tid efter kampagnen, er den samme årsag som ved model 1.

Konvertering til numerisk matrix.

```
full_matrix_m2 <- model.matrix(churn_10 ~ . - 1, data = model2_data)
```

Konvertering af target-variabel til numerisk format.

```
full_label_m2 <- as.numeric(model2_data$churn_10) - 1
```

Opdeling af matrix i trænings- og testdata.

```
train_matrix_m2 <- full_matrix_m2[train_index2, ]  
test_matrix_m2  <- full_matrix_m2[-train_index2, ]
```

Udtræk af target variabelen for træningsdata.

```
y_train_m2 <- model2_data$churn_10[train_index2]
```

Opdeling af labels i trænings- og testdata.

```
train_label_m2 <- full_label_m2[train_index2]  
test_label_m2  <- full_label_m2[-train_index2]
```

Oprettelse af DMatrix til XGBoost.

```
dtrain_m2 <- xgb.DMatrix(data = train_matrix_m2, label = as.numeric(y_train_m2) - 1)  
dtest_m2  <- xgb.DMatrix(data = test_matrix_m2,  
                          label = as.numeric(model2_data$churn_10[-train_index2]) - 1)
```

```
set.seed(47)
```

Cross-validation af XGBoost.

```
xgb_cv_m2 <- xgb.cv(  
  params = list(  
    max_depth = 4,  
    eta = 0.05,  
    subsample = 0.8,  
    colsample_bytree = 0.8,  
    objective = "binary:logistic",  
    eval_metric = "auc"  
  ),  
  data = dtrain_m2,  
  nrounds = 300,  
  nfold = 5,  
  verbose = 0  
)
```

Træning af endelig XGBoost model.

```
xgb_model2 <- xgb.train(  
  params = list(  
    max_depth = 4,  
    eta = 0.05,  
    subsample = 0.8,  
    colsample_bytree = 0.8,  
    objective = "binary:logistic",  
    eval_metric = "auc"  
  ),  
  data = dtrain_m2,  
  nrounds = 300  
)
```

Forudsigelse af sandsynligheder på testdata.

```
xgb_prob2 <- predict(xgb_model2, dtest_m2)
```

Beregning af ROC-kurve.

```
roc_xgb2 <- roc(test_data2$churn_10, xgb_prob2)
```

Setting levels: control = No, case = Yes

Setting direction: controls < cases

Bestemmelse af optimalt threshold via Youden's J.

```
cut_xgb2 <- as.numeric(coords(roc_xgb2, "best", ret = "threshold"))
```

Konvertering af sandsynligheder til klasser.

```
xgb_pred2 <- ifelse(xgb_prob2 > cut_xgb2, "Yes", "No") %>%  
  factor(levels = c("No", "Yes"))
```

Beregning af confusion matrix.

```
cm_xgb2 <- confusionMatrix(xgb_pred2, test_data2$churn_10)
```

11.7 Tabel over mest risikable kunder

Opdeling af pseudo-ID'er i trænings- og testdata

```
train_ids_m2 <- model2_ids[train_index2]  
test_ids_m2 <- model2_ids[-train_index2]
```

Oprettelse af risikotibble.

```
risk_list_m2 <- tibble(  
  pseudo_id = test_ids_m2,  
  churn_probability = xgb_prob2,  
  predicted_class = xgb_pred2  
)
```

Sortering efter churn sandsynlighed.

```
risk_list_sorted_m2 <- risk_list_m2 %>%  
  arrange(desc(churn_probability))
```

Opbygning af endelig risikotabel.

```
risk_table_m2 <- risk_list_sorted_m2 %>%  
  mutate(  
    churn_risk_pct = round(churn_probability * 100, 1),  
    risk_group = case_when(  
      churn_probability >= 0.75 ~ "Høj risiko",  
      churn_probability >= 0.50 ~ "Middel risiko",  
      TRUE ~ "Lav risiko")) %>%  
  select(  
    pseudo_id,  
    churn_risk_pct,  
    predicted_class,  
    risk_group  
  )
```

11.8 Økonomisk analyse af churn efter kampagnen

Definition af listepriis

```
JP_pris <- 199
```

Filtrering af højrisiko-kunder

```
high_risk_m2 <- risk_list_sorted_m2 %>%  
  filter(churn_probability > 0.75)  
n_high_risk_m2 <- nrow(high_risk_m2)
```

Beregning af økonomisk værdi 5% uplift (worst case).

```
saved_5_m2 <- n_high_risk_m2 * 0.05  
value_3m_5_m2 <- saved_5_m2 * JP_pris * 3  
value_6m_5_m2 <- saved_5_m2 * JP_pris * 6  
value_12m_5_m2 <- saved_5_m2 * JP_pris * 12
```

Beregning af økonomisk værdi 15% uplift (realistisk).

```
saved_15_m2 <- n_high_risk_m2 * 0.15  
value_3m_15_m2 <- saved_15_m2 * JP_pris * 3  
value_6m_15_m2 <- saved_15_m2 * JP_pris * 6  
value_12m_15_m2 <- saved_15_m2 * JP_pris * 12
```

Beregning af økonomisk værdi 25% uplift (optimistisk).

```
saved_25_m2 <- n_high_risk_m2 * 0.25  
value_3m_25_m2 <- saved_25_m2 * JP_pris * 3  
value_6m_25_m2 <- saved_25_m2 * JP_pris * 6  
value_12m_25_m2 <- saved_25_m2 * JP_pris * 12
```

Oprettelse af økonomisk overblikstabel.

```
economy_table_m2 <- tibble(  
  scenario = c("5% (Worst case)", "15% (Realistisk)", "25% (Optimistisk)"),  
  højrisiko_kunder = n_high_risk_m2,  
  reddede_kunder = round(c(saved_5_m2, saved_15_m2, saved_25_m2)),  
  besparelse_3m = round(c(value_3m_5_m2, value_3m_15_m2, value_3m_25_m2)),  
  besparelse_6m = round(c(value_6m_5_m2, value_6m_15_m2, value_6m_25_m2)),  
  besparelse_12m = round(c(value_12m_5_m2, value_12m_15_m2, value_12m_25_m2))  
)
```

11.9 Sammenligning af modeller

Udtræk af AUC værdierne for modellerne.

```
auc_log2 <- as.numeric(pROC::auc(roc_log2))  
auc_rf2 <- as.numeric(pROC::auc(roc_rf2))  
auc_xgb2 <- as.numeric(pROC::auc(roc_xgb2))
```

Oprettelse af modelsammenligningstabel.

```
model_sammenligning2 <- tibble(  
  Model = c("Logistisk regression", "Random Forest", "XGBoost"),  
  AUC = round(c(auc_log2, auc_rf2, auc_xgb2), 4),  
  Accuracy = round(c(  
    cm_log2$overall["Accuracy"],  
    cm_rf2$overall["Accuracy"],  
    cm_xgb2$overall["Accuracy"]  
  ), 4),  
  Sensitivity = round(c(  
    cm_log2$byClass["Sensitivity"],
```

```

    cm_rf2$byClass["Sensitivity"],
    cm_xgb2$byClass["Sensitivity"]
  ), 4),
  Specificity = round(c(
    cm_log2$byClass["Specificity"],
    cm_rf2$byClass["Specificity"],
    cm_xgb2$byClass["Specificity"]
  ), 4)
)

knitr::kable(
  model_sammenligning2,
  caption = "Sammenligning af modeller - Model 2 (churn inden for 10 dage efter kampagneslut)",
  col.names = c("Model", "AUC", "Accuracy", "Sensitivitet", "Specificitet")
)

```

Tabel 2: Sammenligning af modeller — Model 2 (churn inden for 10 dage efter kampagneslut)

Model	AUC	Accuracy	Sensitivitet	Specificitet
Logistisk regression	0,7087	0,6533	0,6202	0,8571
Random Forest	0,8018	0,7133	0,6977	0,8095
XGBoost	0,8276	0,8333	0,8605	0,6667


Visualisering af ROC-kurver.

```

plot(roc_log2, col = "steelblue", lwd = 2,
     main = "ROC-kurver - Model 2 (churn_10 efter kampagneslut)")
plot(roc_rf2, col = "darkgreen", lwd = 2, add = TRUE)
plot(roc_xgb2, col = "firebrick", lwd = 2, add = TRUE)
legend("bottomright",
     legend = c(
       paste0("Logistisk regression (AUC = ", round(auc_log2, 3), ")"),
       paste0("Random Forest (AUC = ", round(auc_rf2, 3), ")"),
       paste0("XGBoost (AUC = ", round(auc_xgb2, 3), ")")
     ),
     col = c("steelblue", "darkgreen", "firebrick"),
     lwd = 2)

```

ROC-kurver — Model 2 (churn_10 efter kampagneslut)



Udtræk af variabelvigtighed fra Random Forest.


```
rf_imp2 <- importance(rf_model12) %>%
  as.data.frame() %>%
  rownames_to_column("variabel") %>%
  arrange(desc(MeanDecreaseGini))
```

Visualisering af variabelvigtighed i Random Forest modellen.

```
rf_imp2 %>%
  slice_head(n = 15) %>%
  ggplot(aes(x = reorder(variabel, MeanDecreaseGini), y = MeanDecreaseGini)) +
  geom_col(fill = "darkgreen", alpha = 0.8) +
  coord_flip() +
  labs(
    title = "Variabelvigtighed - Random Forest (Model 2)",
    subtitle = "MeanDecreaseGini: hvor meget variabelen reducerer usikkerhed på tværs af træer",
    x = NULL,
    y = "MeanDecreaseGini"
  ) +
  theme_minimal()
```


Variabelvigtighed — Random Forest (M)

MeanDecreaseGini: hvor meget variablen redu



Udtræk af variabelvigtighed fra XGBoost.


```
xgb_imp2 <- xgb.importance(model = xgb_model2) %>%
  as_tibble()
```

Visualisering af variabelvigtighed i XGBoost modellen.

```
xgb_imp2 %>%
  slice_head(n = 15) %>%
  ggplot(aes(x = reorder(Feature, Gain), y = Gain)) +
  geom_col(fill = "firebrick", alpha = 0.8) +
  coord_flip() +
  labs(
    title = "Variabelvigtighed - XGBoost (Model 2)",
    subtitle = "Gain: hvor meget hver variabel forbedrer modellens præcision",
    x = NULL,
    y = "Gain"
  ) +
  theme_minimal()
```

Variabelvigtighed — XGBoost (Model 2)

Gain: hvor meget hver variabel forbedrer mode



11.10 Cross-validation sammenligning

Udtræk af cross-validation resultater fra logistisk regression.

```
log_cv2_results <- log_cv2$results %>%
  select(ROC, Sens, Spec) %>%
  slice(which.max(ROC)) %>%
  mutate(Model = "Logistisk regression")
```

Udtræk af cross-validation resultater fra Random Forest.

```
rf_cv2_results <- rf_cv2$results %>%
  select(ROC, Sens, Spec) %>%
  slice(which.max(ROC)) %>%
  mutate(Model = "Random Forest")
```

Udtræk af cross-validation resultater fra XGBoost.

```
xgb_cv2_results <- tibble(
  Model = "XGBoost",
  ROC   = max(xgb_cv_m2$evaluation_log$test_auc_mean),
  Sens  = NA, # xgb.cv giver ikke Sens/Spec direkte
  Spec  = NA
)
```

Sammenstilling af cross-validation resultater.

```
cv_sammenligning2 <- bind_rows(
  log_cv2_results,
  rf_cv2_results,
  xgb_cv2_results) %>%
  select(Model, ROC, Sens, Spec)
```

Vi har udviklet en klassifikationsmodel, der forudsiger, om en kunde fortsætter efter kampagneperioden (churn eller ej). Vi har brugt korrekt feature engineering og fjernet dataleakage, og lavet tre forskellige klassifikationsmodeller. XGBoost modellen opnår den højeste AUC på 82,8% og dermed den bedste balance mellem sensitivitet og specificitet, hvor den finder 86% af churnerne og 66,7% af de kunder der fortsætter. Random Forest har en AUC på 80,2% og finder 69,8% af churnerne, og 81% af ikke-churnerne. Logistisk regression er den svageste model med AUC på 70.9%. Vi har valgt XGBoost da den har den højeste AUC og den bedste balance mellem sensitivitet og specificitet.

11.11 em som CSV-filer til Power BI

Eksport af resultater til Power BI.

```
risk_list_m2 %>%
  mutate(across(where(is.numeric), ~ round(.x, 4))) %>%
  write.table("data/model2_risiko_liste.csv",
    sep = ";", dec = ".", row.names = FALSE, quote = FALSE)

risk_table_m2 %>%
  mutate(across(where(is.numeric), ~ round(.x, 4))) %>%
  write.table("data/model2_risiko_tabel.csv",
    sep = ";", dec = ".", row.names = FALSE, quote = FALSE)

economy_table_m2 %>%
  mutate(across(where(is.numeric), ~ round(.x, 4))) %>%
  write.table("data/model2_økonomisk_besparelse.csv",
    sep = ";", dec = ".", row.names = FALSE, quote = FALSE)
```

```

xgb_imp2 %>%
  mutate(across(where(is.numeric), ~ round(.x, 4))) %>%
  write.table("data/model2_xgb_variabel_vigtighed.csv",
             sep = ";", dec = ".", row.names = FALSE, quote = FALSE)

model_sammenligning2 %>%
  mutate(across(where(is.numeric), ~ round(.x, 4))) %>%
  write.table("data/model2_sammenligning.csv",
             sep = ";", dec = ".", row.names = FALSE, quote = FALSE)

```

12 Væsentligste konklusioner

13 Literaturliste

Bang, Claus Grand. 2024. *Data-Driven Decision-Making for Business*. 1. udg. Routledge.

VFF. 2025. "Transskriberede interviews". <https://eadania.mrooms.net/mod/hsuforum/discuss.php?d=33332>.

Eksempler på afsnit i bilag:

A Dataforståelse (CRISP-DM)

A.1 Forretningsforståelse

Afklare formål, behov og succeskriterier (hvorfor laver vi analysen?).

A.2 Dataforståelse

Indsamle data, få overblik, undersøge datakvalitet og finde mønstre.

A.3 Dataklargøring

Rense, strukturere og omforme data, så det er klar til analyse/modellering.

A.4 Modellering

Udvikle og træne modeller samt justere parametre.

A.5 Evaluering

Vurdere om modellen/resultatet er korrekt og brugbart ift. forretningsmålet.

A.6 Implementering

Sætte løsningen i drift: rapport, dashboard, automatisering eller system

B Dataklargørelse

B.1 Hente data fra Superstats og gør dem tidy

B.2 Hente data fra DMI og gør dem tidy

B.3 Hente data fra nager.at og gør dem tidy

B.4 Hente Bjarnes data og gør dem tidy

B.5 RSQLight

B.6 Download jointet datasæt, formatér behørigt, og gør data klar til preprocessing

B.7 Preprocess - dan flere variabler og lav ét datasæt uden missing med en række for hver hjemmekamp, og fjern alle variabler, som ikke skal indgå i

C Modellering - herunder opdeling i et trænings- og testdatasæt - med et seed = jeres holdnummer.

C.1 Stor model - linenær regression med alle variabler

C.2 Lasso / Ridge - husk at bruge CV til at optimere lambda

C.3 Subset selection metoder (brug mindst én)

C.4 Sammenlign på validation de forskellige MSE fra hver model

D Evaluering

D.1 Hvordan er Test-MSE sammenlignet med CV-MSE

D.2 Fortokning

D.3 Prædiktion på nye data (fx best-case/worst-case scenario for de første kampe i foråret)

D.4 Sammenlign resultatet med formålet med undersøgelsen.

E Eksempler på markdown-sproget

E.1 Her hentes et billede

Her er et eksempel på anvendelse af en png fil, som skal ligge i dit working directory. Tekst mellem [] er figurteksten, som du ønsker i din opgave. Tekst mellem () er (placering og) navn på figuren. Tekst mellem {} er et henvisningsnavn, som du kan bruge til at henvise til figuren i din tekst.

E.2 Referencer

Her er et eksempel på en figur, som jeg henviser til 2 . En figur som JEG har lavet længere nede i koden.


Sådan henviser/refererer du til en figur: 1 (Billedet fra før).

Her et eksempel med en tabel 3, som JEG har lavet længere nede.

Her er noget tekst blabla, og nu vil jeg gerne lave en reference til afsnit 1.1.

Reference f.eks. fra interviews bla.bla..bla... (VFF 2025) eller en bog (Bang 2024) osv.

Reference til en ligning: 1




Figur 1: Faserne i CRISP-DM.

$$\hat{T}_t = \frac{1}{m} \sum_{j=-k}^k y_{t+j} \quad (1)$$

Jeg kan også referere til f.eks. en værdi, som jeg har udregnet i en kode chunk:

I forbindelse med den simple lineære regression er $R^2 = 0,59$

Lav gerne mange kode chunks i stedet for at have lange chunks - det giver et bedre overblik. Indholdet i en kode chunk skal være sammenhængende. Men lav gerne flere i forbindelse med fx, at du laver en Lasso regression.



Figur 2: Australsk BNP pr capita

Tabel 3: Outliers og indflydelsesrige observationer.

Observation	Outlier	Høj leverage	Indflydelsesrig observation	Reference til plot
16	Ja	Nej	Nej	Residuals vs Fitted, Q-Q Plot, Scale-Location, Boxplot
17	Ja	Nej	Nej	Residuals vs Fitted, Q-Q Plot, Scale-Location
39	Nej	Ja	Nej	Residuals vs Leverage
117	Nej	Ja	Ja	Residuals vs Leverage (Cook's Distance)

F Fed og kursiv, og punktform

- **Daniel** Daniel skreved med fed skrift
 - *Olga* Olga skrevet i kursiv
 - * ***Palle*** Palle skrevet med fed skrift og i kursiv

“-” angiver punktform - bemærk de forskellige niveauer

G Formler (m.m)

G.1 Gennemsnit

Gennemsnittet af y : de observerede (faktiske) værdier.

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$